

BÀI TẬP THỰC HÀNH

Chủ đề: One Pipeline, Many Classifiers cho bài toán phân loại văn bản tiếng Việt

1. Tên bài tập

Phân loại bài báo tiếng Việt thuộc chủ đề Kinh tế/Kinh doanh hay không

2. Bối cảnh

Xây dựng một hệ thống phân loại bài báo tiếng Việt thành hai nhóm:

- **Nhóm 1:** Bài báo thuộc chủ đề **Kinh tế/Kinh doanh**
- **Nhóm 0:** Bài báo **không thuộc** chủ đề Kinh tế/Kinh doanh

3. Mục tiêu học tập

Sau khi hoàn thành bài này, sinh viên cần đạt được các mục tiêu sau:

1. Hiểu và triển khai được pipeline cơ bản cho bài toán phân loại văn bản.
2. Biết cách chuẩn bị dữ liệu, tiền xử lý và biểu diễn văn bản bằng **BoW** và **TF-IDF**.
3. Huấn luyện và so sánh hiệu quả của các mô hình:
 - Multinomial Naive Bayes
 - Logistic Regression
 - SVM
4. Biết đánh giá mô hình bằng nhiều chỉ số thay vì chỉ nhìn vào accuracy.
5. Nhận ra các vấn đề thường gặp trong thực tế như:
 - dữ liệu mất cân bằng,
 - không có mô hình nào luôn tốt nhất,
 - feature quá nhiều có thể gây nhiễu,
 - cải tiến mô hình cần dựa trên kết quả đánh giá.
6. Rèn kỹ năng phân tích kết quả và thực nghiệm.

4. Mô tả bài toán

Sinh viên xây dựng một hệ thống nhận đầu vào là một bài báo tiếng Việt và dự đoán xem bài báo đó có thuộc nhóm **Kinh tế/Kinh doanh** hay không.

Bài toán được xem như một bài toán **phân loại nhị phân**:

- **1:** Kinh tế/Kinh doanh
- **0:** Không phải Kinh tế/Kinh doanh

5. Dữ liệu

5.1. Nguồn dữ liệu

Sinh viên sử dụng dữ liệu do chính nhóm tự crawl từ một hoặc nhiều trang báo điện tử tiếng Việt.

5.2. Yêu cầu dữ liệu tối thiểu

Mỗi mẫu dữ liệu nên có ít nhất các trường sau:

- tiêu đề bài báo
- mô tả ngắn/tóm tắt nếu có
- nội dung bài báo
- chuyên mục
- đường dẫn bài viết

5.3. Gán nhãn

Sinh viên gán nhãn dựa trên **chuyên mục** của bài báo:

- Các bài thuộc các mục như **Kinh tế, Kinh doanh, Tài chính, Thị trường, Chứng khoán** được gán nhãn **1**
- Các bài thuộc các mục khác như **Thể thao, Giải trí, Giáo dục, Đời sống, Sức khỏe, Công nghệ, Du lịch...** được gán nhãn **0**

5.4. Quy mô dữ liệu

Khuyến nghị mỗi nhóm chuẩn bị tối thiểu:

- **2000 bài báo**
- trong đó nên có sự **mất cân bằng lớp vừa phải**, ví dụ:
 - 600–800 bài thuộc lớp 1
 - 1200–1600 bài thuộc lớp 0

Mục đích: để quan sát được ảnh hưởng của mất cân bằng dữ liệu đến kết quả phân loại.

5.5. Làm sạch dữ liệu

Sinh viên cần kiểm tra và xử lý:

- bài trùng lặp
- bài rỗng hoặc thiếu nội dung
- bài có nội dung quá ngắn
- lỗi mã hóa ký tự nếu có

6. Yêu cầu thực hiện cụ thể

Ngày 20/03/2026

Phần A. Chuẩn bị dữ liệu

Sinh viên cần:

1. Thu thập dữ liệu
2. Gán nhãn
3. Mô tả tập dữ liệu:
 - tổng số mẫu
 - số mẫu mỗi lớp
 - tỷ lệ giữa hai lớp
 - ví dụ minh họa một vài mẫu dữ liệu

Cần nhận xét: dữ liệu có cân bằng hay không, và dự đoán trước điều này có thể ảnh hưởng thế nào đến mô hình.

Gợi ý cấu trúc CSV tối thiểu:

- id: mã bài viết
- url: link bài báo
- category: chuyên mục gốc của bài báo
- label: nhãn phân loại
- title: tiêu đề
- desc: mô tả ngắn / sapo
- text: nội dung bài báo

→ Lưu ý: Ở bước Tiền xử lý, nên copy dữ liệu sang 1 cột riêng

Phần B. Tiền xử lý văn bản

Sinh viên thực hiện các bước tiền xử lý đã học, ví dụ:

- chuẩn hóa chữ
- loại bỏ ký tự đặc biệt không cần thiết
- tách từ
- loại bỏ stopwords nếu thấy phù hợp
- ghép các trường văn bản để tạo đầu vào cuối cùng

Sinh viên phải mô tả rõ:

- đầu vào mô hình là gì
(ví dụ chỉ dùng title, hoặc title + summary, hoặc title + content)
- các bước tiền xử lý đã áp dụng
- lý do chọn cách đó

Phần C. Biểu diễn văn bản

Sinh viên phải thử ít nhất 2 cách biểu diễn đặc trưng:

1. **Bag of Words**
2. **TF-IDF**

Có thể bắt đầu với unigram. Nhóm nào muốn mở rộng có thể thử thêm bigram.

Phần D. Xây dựng mô hình

Sinh viên phải huấn luyện và so sánh ít nhất 3 mô hình:

1. **Multinomial Naive Bayes**
2. **Logistic Regression**
3. **Support Vector Machine (SVM)**

Lưu ý:

- Cần giữ quy trình xử lý tương đối thống nhất để việc so sánh công bằng.
- Phải mô tả rõ dữ liệu được chia như thế nào, ví dụ train/test hoặc train/validation/test.

Phần E. Đánh giá mô hình

Sinh viên bắt buộc đánh giá bằng các chỉ số sau:

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix

Ngoài ra, sinh viên phải phân tích riêng cho lớp **Kinh tế/Kinh doanh**, không chỉ nêu kết quả chung.

Yêu cầu phân tích

Sinh viên cần trả lời các câu hỏi như:

- Mô hình nào cho accuracy cao nhất?
- Mô hình nào nhận diện tốt hơn lớp Kinh tế/Kinh doanh?
- Có trường hợp nào accuracy cao nhưng kết quả thực tế vẫn chưa tốt không?
- Dữ liệu mất cân bằng ảnh hưởng như thế nào?

Ngày 27/03/2026

Phần F. Cải tiến mô hình

Sau khi chạy kết quả ban đầu, sinh viên phải thực hiện **ít nhất 2 hướng cải tiến** và phân tích tác động của từng hướng.

Có thể chọn trong các hướng sau:

Hướng 1: Giảm số lượng đặc trưng

Ví dụ giới hạn số feature để xem việc giảm độ thừa có giúp mô hình tốt hơn hay không.

Hướng 2: Xử lý mất cân bằng lớp

Ví dụ:

- class weight
- resampling

Hướng 3: So sánh BoW và TF-IDF

Phân tích xem biểu diễn nào phù hợp hơn với bài toán.

Hướng 4: Thử n-gram

Ví dụ so sánh unigram với unigram + bigram.

Hướng 5: Thử đầu vào khác nhau

Ví dụ:

- chỉ dùng title
- dùng title + summary
- dùng full content

Hướng 6: Điều chỉnh tham số mô hình

Ví dụ tinh chỉnh các tham số cơ bản của Naive Bayes, Logistic Regression hoặc SVM.

Mỗi cải tiến phải có:

- lý do thử
- cách thực hiện
- kết quả trước và sau
- nhận xét

Hướng 7: Xử lý với từ tiếng Việt

Ví dụ: gộp cách từ ghép như “kinh_tế”, “thể_thao”, ... để cải tiến chất lượng bộ dữ liệu

7. Nội dung báo cáo cần nộp (Ghi ngắn gọn)

Mỗi nhóm nộp **1 báo cáo** với các phần sau:

7.1. Giới thiệu bài toán

- Mô tả bài toán

7.2. Dữ liệu

- Nguồn dữ liệu
- Cách crawl
- Cách gán nhãn

- Quy mô dữ liệu
- Phân bố lớp
- Ví dụ dữ liệu

7.3. Tiền xử lý

- Các bước đã thực hiện
- Giải thích lý do

7.4. Biểu diễn dữ liệu

- BoW
- TF-IDF
- Các thiết lập chính

7.5. Mô hình

- Naive Bayes
- Logistic Regression
- SVM
- Cách chia tập dữ liệu
- Cách huấn luyện

7.6. Kết quả thực nghiệm

- Bảng so sánh kết quả
- Confusion Matrix
- Nhận xét chi tiết

7.7. Cải tiến

- Mô tả ít nhất 2 cải tiến
- So sánh kết quả trước/sau
- Nhận xét

7.8. Kết luận

- Mô hình tốt nhất theo nhóm là mô hình nào
- Vì sao chọn mô hình đó
- Bài học rút ra từ thực nghiệm

8. Sản phẩm cần nộp

Mỗi nhóm nộp:

1. **File báo cáo**
2. **Notebook hoặc source code (Link đính kèm trong báo cáo)**
3. **File dữ liệu đã xử lý (Link đính kèm trong báo cáo)**

9. Một số yêu cầu bắt buộc khi trình bày kết quả

Sinh viên **không được chỉ nêu mỗi accuracy** rồi kết luận mô hình tốt nhất.

Báo cáo phải thể hiện rõ:

- sự khác nhau giữa các mô hình
- ảnh hưởng của mất cân bằng lớp
- vì sao cần xem thêm precision, recall, F1
- vì sao confusion matrix quan trọng
- vì sao một cải tiến có thể giúp lớp thiểu số nhưng chưa chắc làm accuracy tăng

10. Câu hỏi thảo luận bắt buộc

Trong báo cáo, mỗi nhóm phải trả lời ngắn gọn nhưng rõ ràng các câu sau:

1. Vì sao trong bài toán này không nên chỉ nhìn vào accuracy?
2. Mô hình nào phát hiện tốt hơn lớp Kinh tế/Kinh doanh? Dựa trên chỉ số nào?
3. Khi thay đổi classifier nhưng giữ nguyên pipeline, kết quả thay đổi như thế nào?
4. BoW và TF-IDF khác nhau thế nào trong thực nghiệm của nhóm?
5. Dữ liệu mất cân bằng ảnh hưởng thế nào đến kết quả?
6. Sau khi cải tiến, metric nào thay đổi rõ nhất?
7. Nhóm rút ra kết luận gì từ nhận định:

“Không có mô hình nào luôn tốt nhất cho mọi bộ dữ liệu.”

11. Tiêu chí chấm điểm

Sen đề xuất rubric như này để bám đúng mục tiêu bài học:

1. Dữ liệu và chuẩn bị dữ liệu — 20 điểm

- Thu thập đủ dữ liệu, hợp lý: 8 điểm
- Gán nhãn rõ ràng, đúng logic: 6 điểm
- Làm sạch dữ liệu và mô tả phân bố lớp: 6 điểm

2. Tiền xử lý và biểu diễn văn bản — 15 điểm

- Tiền xử lý phù hợp: 7 điểm
- Triển khai BoW và TF-IDF đúng: 8 điểm

3. Xây dựng mô hình — 20 điểm

- Huấn luyện đủ 3 mô hình yêu cầu: 12 điểm
- Tổ chức thí nghiệm rõ ràng, so sánh công bằng: 8 điểm

4. Đánh giá và phân tích kết quả — 20 điểm

- Sử dụng đầy đủ các metric: 8 điểm
- Có confusion matrix và phân tích hợp lý: 6 điểm
- Nhận xét có chiều sâu, không chỉ mô tả số liệu: 6 điểm

5. Cải tiến mô hình — 15 điểm

- Thực hiện ít nhất 2 cải tiến: 8 điểm
- So sánh trước/sau và giải thích hợp lý: 7 điểm

6. Báo cáo và trình bày — 10 điểm

- Báo cáo rõ ràng, có cấu trúc: 5 điểm
- Trình bày logic, kết luận thuyết phục: 5 điểm

Tổng: 100 điểm

12. Mức điểm cộng

Có thể cộng thêm tối đa **10 điểm khuyến khích** cho các nhóm có mở rộng tốt, ví dụ:

- thử thêm n-gram

- thử thêm cách chọn đầu vào
 - so sánh thêm thời gian huấn luyện giữa các mô hình
 - trực quan hóa kết quả rõ ràng
 - có nhận xét sâu, đúng bản chất vấn đề
-

13. Lưu ý

- Không sao chép dữ liệu hoặc code của nhóm khác.
 - Không chỉ tập trung “làm cho điểm số cao nhất”, mà phải giải thích được **vì sao kết quả như vậy**.
 - Trọng tâm của bài này là **pipeline, so sánh mô hình, đánh giá và cải tiến**, không phải chạy thật nhiều mô hình phức tạp.
-

14. Gợi ý định hướng thực hiện

Để làm tốt bài này, nhóm nên đi theo trình tự:

1. Chuẩn bị dữ liệu sạch và gán nhãn rõ ràng
 2. Chạy baseline đơn giản trước
 3. So sánh 3 mô hình trên cùng pipeline
 4. Đọc kỹ confusion matrix và các metric
 5. Chọn điểm yếu lớn nhất của hệ thống
 6. Thực hiện cải tiến có chủ đích
 7. Viết kết luận dựa trên bằng chứng thực nghiệm
-

15. Kết quả mong đợi

Sau bài tập này, sinh viên cần hiểu được rằng:

- pipeline phân loại văn bản không chỉ là train mô hình
 - cùng một bài toán nhưng thay classifier có thể cho kết quả khác nhau
 - accuracy chưa chắc phản ánh đầy đủ chất lượng mô hình
 - cải tiến mô hình phải dựa trên phân tích cụ thể
 - trong NLP thực tế, lựa chọn mô hình cần gắn với dữ liệu và mục tiêu bài toán
-

Bài tập ngày 03/04

Tự huấn luyện Word2Vec trên tập văn bản bài báo đã có, sau đó biểu diễn mỗi bài báo bằng **trung bình vector** từ và dùng Logistic Regression hoặc SVM để phân loại bài báo Kinh tế/Kinh doanh hay không. So sánh kết quả với TF-IDF và rút ra nhận xét.

Các bước thực hiện:

1. Dừng lại bộ dữ liệu bài báo đã crawl và tiền xử lý. (Tương tự bài tập cũ)
2. Tách văn bản thành token. (nên gộp các từ ghép theo Hướng 7: Xử lý với từ tiếng Việt)
3. Train một mô hình **Word2Vec** trên toàn bộ tập văn bản. (Hỏi ChatGPT)
4. Biểu diễn mỗi bài báo bằng cách **lấy trung bình vector của các từ** trong bài. (Hỏi ChatGPT)
5. Dùng các vector văn bản đó để train:
 - o Logistic Regression
 - o SVM
6. So sánh với kết quả TF-IDF trước đó.
7. **Hỏi ChatGPT/AI xem** có thể điều chỉnh các tham số như thế nào để có thể cải thiện chất lượng phân loại khi train Word2Vec → Thử thay đổi và kiểm tra lại chất lượng model.

Bài tập ngày 10/04

Chủ đề: Từ pipeline cổ điển sang deep learning cho bài toán phân loại văn bản tiếng Việt

Làm quen với text classification bằng CNN và LSTM, sau đó mở rộng sang bài toán phân loại bài báo tiếng Việt thuộc chủ đề Kinh tế/Kinh doanh hay không

➤ Bối cảnh

Ở các bài trước, sinh viên đã làm quen với pipeline phân loại văn bản theo hướng cổ điển:

- tiền xử lý văn bản
- biểu diễn dữ liệu bằng BoW / TF-IDF / Word2Vec average
- huấn luyện classifier như Naive Bayes, Logistic Regression, SVM
- đánh giá bằng Accuracy, Precision, Recall, F1-score, Confusion Matrix

Trong bài này, sinh viên chuyển sang một hướng tiếp cận mới: **deep learning cho text classification**.

Thay vì tự tạo một vector đặc trưng cố định cho toàn văn bản rồi đưa vào classifier, sinh viên sẽ thử pipeline:

text → tokenize → sequence → padding → embedding → CNN/LSTM → output

Bài tập được chia thành 2 mức:

- **Phần 1:** làm demo nhỏ để hiểu flow của CNN
- **Phần 2:** thay CNN bằng LSTM để so sánh
- **Phần mở rộng:** áp dụng tư duy đó vào chính bài toán phân loại bài báo tiếng Việt đã làm ở bài trước

- **Công cụ gợi ý**
 - pandas
 - numpy
 - scikit-learn
 - tensorflow hoặc keras
- **Các bước cụ thể**

PHẦN A. DEMO 1 – CNN ĐƠN GIẢN ĐỂ MINH HỌA FLOW

Code demo:

<https://drive.google.com/file/d/1yNrCbjumFf-0PYm0fCraZ3l5cCQdL4YI/view?usp=sharing>

1. Mục tiêu của phần này

Mục tiêu của phần này **không phải tối ưu độ chính xác**, mà là để hiểu rõ pipeline đầu vào của deep learning cho text classification.

2. Dữ liệu

Sinh viên sử dụng một tập dữ liệu toy rất nhỏ gồm một số câu ngắn thuộc 2 lớp:

- lớp 1: Kinh tế/Kinh doanh
- lớp 0: Không thuộc Kinh tế/Kinh doanh

Ví dụ:

- “cổ phiếu ngân hàng tăng mạnh”
- “thị trường chứng khoán giảm điểm”
- “doanh thu quý này tăng cao”
- “đội tuyển bóng đá thắng trận”
- “ca sĩ ra mắt album mới”
- “bộ phim mới đạt doanh thu phòng vé cao”

3. Yêu cầu thực hiện

Sinh viên cần thực hiện lần lượt các bước sau:

Bước 1. Chia dữ liệu train/test

- Dùng `train_test_split`
- Mô tả rõ:
 - dữ liệu nào vào train
 - dữ liệu nào vào test
- Giải thích vì sao phải tách train/test

Bước 2. Tạo tokenizer

- Dùng `Tokenizer(...)`
- Cho tokenizer học vocabulary từ tập train
- Giải thích:
 - token là gì
 - vì sao phải fit tokenizer trên train trước
 - vì sao test phải dùng lại tokenizer của train

Bước 3. Chuyển text thành sequence số nguyên

- Dùng `texts_to_sequences(...)`
- Giải thích:
 - text được đổi thành danh sách token id như thế nào
 - sequence này khác BoW ở điểm nào

Bước 4. Padding

- Dùng `pad_sequences(...)`
- Chọn một giá trị `max_len`
- Giải thích:
 - vì sao phải padding
 - dữ liệu sau padding có dạng gì

Bước 5. Xây dựng mô hình CNN

Sinh viên cần tạo một mô hình CNN đơn giản với các thành phần tối thiểu:

- Embedding
- Conv1D
- GlobalMaxPooling1D
- Dense
- Dense output với sigmoid

Bước 6. Compile và train mô hình

- Chọn optimizer phù hợp, ví dụ adam
- Dùng loss phù hợp cho phân loại nhị phân, ví dụ `binary_crossentropy`
- Train mô hình với số epoch nhỏ

Bước 7. Đánh giá và dự đoán thử

- Đánh giá trên tập test
- In ra accuracy
- Thử dự đoán 1–2 câu mới
- Giải thích kết quả xác suất đầu ra

4. Yêu cầu giải thích bắt buộc

Trong báo cáo, sinh viên phải giải thích ngắn gọn nhưng rõ:

1. `Tokenizer.fit_on_texts(...)` làm gì
2. `texts_to_sequences(...)` làm gì
3. `pad_sequences(...)` làm gì
4. `Embedding(...)` đóng vai trò gì
5. `Conv1D(...)` đang học cái gì theo trực giác
6. `GlobalMaxPooling1D()` giúp gì
7. Vì sao pipeline này khác với TF-IDF + Logistic/SVM

5. Sản phẩm cần nộp cho Phần A

Sinh viên nộp:

- file notebook hoặc file `.py`
- phần giải thích ngắn cho từng bước
- ảnh chụp hoặc output minh họa:
 - sequence sau tokenization
 - dữ liệu sau padding
 - accuracy test
 - dự đoán thử cho câu mới

PHẦN B. DEMO 2 – ĐỔI TỪ CNN SANG LSTM

Code demo:

https://drive.google.com/file/d/1-xL_bNKMZK4OtqanBBom7w0AzFryL6sl/view?usp=sharing

1. Mục tiêu của phần này

Giữ nguyên pipeline đầu vào như Phần A, nhưng thay kiến trúc mô hình từ CNN sang LSTM để sinh viên thấy:

- input pipeline có thể giữ nguyên
- phần thay đổi chính nằm ở “thân” của mô hình
- CNN và LSTM là hai cách xử lý sequence khác nhau

2. Yêu cầu thực hiện

Sinh viên dùng lại:

- cùng bộ dữ liệu
- cùng cách train/test split
- cùng tokenizer
- cùng max_len
- cùng cách padding

Sau đó thay mô hình CNN bằng mô hình LSTM đơn giản, ví dụ gồm:

- Embedding
- LSTM
- Dense
- Dense output với sigmoid

3. Yêu cầu phân tích

Sinh viên cần viết nhận xét ngắn về các điểm sau:

1. Phần nào của pipeline giữ nguyên giữa CNN và LSTM
2. Phần nào thay đổi
3. Về trực giác:
 - CNN phù hợp với việc học pattern cục bộ như thế nào
 - LSTM phù hợp với việc học chuỗi như thế nào
4. Kết quả CNN và LSTM có khác nhau không
5. Với bộ dữ liệu toy rất nhỏ này, có nên kết luận mô hình nào tốt hơn hẳn không, vì sao

4. Sản phẩm cần nộp cho Phần B

- code mô hình LSTM
- kết quả chạy
- phần so sánh ngắn giữa CNN và LSTM